

Q-Learning Tabanlı Akıllı Kargo Dolabı Yönetim Sistemi

25462877001 Ahsen Konca

9 Temmuz 2026

Özet

Bu çalışmada, akıllı kargo dolaplarında farklı özelliklere sahip paketlerin uygun dolaplara yerleştirilmesi problemi reinforcement learning yaklaşımıyla ele alınmıştır. Problemde paket boyutu, teslimat önceliği, kırılabilirlik ve soğuk zincir ihtiyacı gibi kriterler dikkate alınmıştır. Ajanın amacı, gelen paketleri uygun dolaplara yerleştirirken sınırlı dolap kapasitesini verimli kullanmak ve uzun vadeli toplam ödülü artırmaktır. Çalışmada Q-Learning algoritması kullanılmış, performans Random Agent ve Rule-Based Agent ile karşılaştırılmıştır. Ayrıca eğitim süreci ödül grafikleri, başarı oranı, kabul oranı, hata oranı ve simülasyon görselleriyle analiz edilmiştir.

1 Giriş

E-ticaret ve kargo teslimat sistemlerinin yaygınlaşmasıyla birlikte akıllı kargo dolapları önemli bir kaynak yönetimi problemi haline gelmiştir. Bu sistemlerde farklı boyutlarda ve farklı ihtiyaçlara sahip paketlerin sınırlı sayıdaki dolaplara doğru şekilde yerleştirilmesi gerekir. Yanlış bir yerleştirme kararı, ilerleyen adımlarda daha büyük veya özel koşullu paketler için uygun dolap kalmamasına neden olabilir.

Bu projede akıllı kargo dolabı yönetimi problemi reinforcement learning yöntemiyle modellenmiştir. Amaç, ajanın deneme-yanılma yoluyla hangi durumda hangi dolap seçiminin daha avantajlı olduğunu öğrenmesidir. Projenin ilk sürümünde yalnızca küçük, orta ve büyük paket boyutları dikkate alınırken, genişletilmiş sürümde daha gerçekçi kriterler eklenmiştir.

2 Problem Tanımı

Sisteme her adımda rastgele özelliklere sahip bir paket gelmektedir. Ajan bu paketi mevcut boş dolap durumuna göre uygun bir dolaba yerleştirmeye çalışır. Dolap kapasitesi sınırlıdır ve bazı dolap tipleri özel paketler için daha değerlidir.

Paket özellikleri aşağıdaki gibidir:

- Paket boyutu: küçük, orta, büyük, XL
- Paket önceliği: standart, express, acil
- Soğuk zincir ihtiyacı: var veya yok

- Kırılabilirlik durumu: var veya yok

Dolap tipleri ise şu şekildedir:

- Küçük dolap
- Orta dolap
- Büyük dolap
- XL dolap
- Soğuk zincir dolabı

Bu yapı sayesinde problem yalnızca boyut eşleştirme problemi olmaktan çıkarılmış, daha gerçekçi bir karar verme problemine dönüştürülmüştür.

3 Reinforcement Learning Yaklaşımı

Reinforcement learning, bir ajanın ortamla etkileşime girerek ödül sinyali üzerinden öğrenmesini sağlayan bir makine öğrenmesi yaklaşımıdır. Bu projede ajan, her adımda bir dolap seçimi yapar. Seçilen aksiyonun sonucunda ortam ajana bir ödül veya ceza verir. Ajan bu deneyimlerden yararlanarak zaman içinde daha iyi kararlar vermeyi öğrenir.

Projede tablo tabanlı Q-Learning algoritması kullanılmıştır. Q-Learning, her durum-aksiyon çifti için bir değer tutar. Bu değer, ilgili aksiyonun o durumda uzun vadede ne kadar faydalı olduğunu temsil eder.

Q-Learning güncelleme formülü şu şekildedir:

$$Q(s, a) \leftarrow Q(s, a) + \alpha \left[r + \gamma \max_{a'} Q(s', a') - Q(s, a) \right] \quad (1)$$

Burada s mevcut durumu, a seçilen aksiyonu, r alınan ödül, s' sonraki durumu, α öğrenme oranını ve γ gelecekteki ödüllerin önemini ifade eder.

4 Durum ve Aksiyon Tasarımı

Projede state abstraction kullanılmıştır. Her dolap tek tek takip edilmemiş, bunun yerine her dolap tipinde kaç boş yer kaldığı tutulmuştur. Bu yaklaşım durum uzayını daha yönetilebilir hale getirir.

Kullanılan durum yapısı aşağıdaki gibidir:

```
(
  empty_small,
  empty_medium,
  empty_large,
  empty_xlarge,
  empty_cold,
  package_size,
  package_priority,
  cold_required,
  fragile
)
```

Örneğin aşağıdaki durum:

(5, 4, 3, 2, 1, 2, 1, 0, 1)

5 küçük, 4 orta, 3 büyük, 2 XL ve 1 soğuk zincir dolabımın boş olduğunu; gelen paketin büyük, express öncelikli, soğuk zincir gerektirmeyen ve kırılğan bir paket olduğunu ifade eder.

Ajanın seçebileceği aksiyonlar Tablo 1 üzerinde verilmiştir.

Tablo 1: Aksiyonlar	
Aksiyon	Anlamı
0	Küçük dolaba yerleştir
1	Orta dolaba yerleştir
2	Büyük dolaba yerleştir
3	XL dolaba yerleştir
4	Soğuk zincir dolabına yerleştir

5 Ödül Fonksiyonu

Ödül fonksiyonu, ajanın yalnızca paketi herhangi bir dolaba koymasını değil, dolap kapasitesini stratejik şekilde kullanmasını hedefler. Bu nedenle doğru boyuta yerleştirme, özel paketleri uygun dolaba yönlendirme ve gereksiz büyük dolap kullanımından kaçınma ödül fonksiyonuna dahil edilmiştir.

Tablo 2: Ödül fonksiyonunda dikkate alınan kriterler

Durum	Etki
Paketin tam uygun boyuttaki dolaba yerleştirilmesi	Pozitif ödül
Bir üst boy dolabın kullanılması	Daha düşük pozitif ödül
Gereksiz büyük veya XL dolap kullanımı	Ceza
Soğuk zincir paketinin soğuk dolaba yerleştirilmesi	Ek ödül
Soğuk zincir paketinin normal dolaba yerleştirilmesi	Büyük ceza
Geçersiz aksiyon seçilmesi	Büyük ceza
Kırılğan paketin uygun yerleştirilmesi	Ek ödül

Bu reward engineering yaklaşımı sayesinde ajan, sadece kısa vadeli doğru kararı değil, uzun vadeli kapasite kullanımını da öğrenmeye yönlendirilmiştir.

6 DeneySEL Kurulum

Eğitimde kullanılan temel parametreler Tablo 3 üzerinde gösterilmiştir.

Tablo 3: Eğitim parametreleri

Parametre	Değer
Episode sayısı	6000
Maksimum step	40
Learning rate	0.1
Discount factor	0.92
Başlangıç epsilon	0.35
Minimum epsilon	0.02
Epsilon decay	0.996

Ajanın keşif ve sömürü dengesini sağlamak için epsilon-greedy stratejisi kullanılmıştır. Eğitim başında ajan daha fazla rastgele aksiyon seçerken, zamanla epsilon değeri azaltılmış ve ajan öğrendiği Q-değerlerine daha fazla güvenmeye başlamıştır.

7 Karşılaştırılan Ajanlar


Modelin başarısını değerlendirmek için üç farklı ajan karşılaştırılmıştır:

- **Q-Learning Agent:** Ortamla etkileşim kurarak Q-tablosu öğrenen ajandır.
- **Rule-Based Agent:** Elle yazılmış kurallara göre karar veren sezgisel ajandır.
- **Random Agent:** Kararlarını rastgele veren referans ajandır.

Bu karşılaştırma, öğrenen ajanın rastgele karar veren bir ajana göre avantajını ve kural tabanlı yaklaşımla rekabet seviyesini göstermektedir.


8 Sonuçlar ve Grafikler

Eğitim sonucunda toplam ödül, hareketli ortalama ödül, başarı oranı, kabul oranı, hatalı hamle oranı ve Q-tablosu büyümesi gibi metrikler incelenmiştir.




Şekil 1: Episode bazlı toplam ödül grafiği

Toplam ödül grafiği, ajanın her episode sonunda aldığı toplam ödülü göstermektedir. Genişletilmiş problemde durum uzayı daha büyük olduğu için ödül değerlerinde dalgalanmalar görülebilir.




Şekil 2: Hareketli ortalama ödül grafiği

Hareketli ortalama grafiği, ham ödül grafiğindeki dalgalanmaları azaltarak öğrenme eğilimini daha okunabilir hale getirir.




Şekil 3: Başarı oranı grafiği

Başarı oranı, pozitif toplam ödül alınan episode'ların hareketli ortalaması olarak hesaplanmıştır.



Şekil 4: Kabul oranı ve hatalı hamle oranı

Bu grafik, eğitim boyunca paketin kabul edilme oranı ile geçersiz karar oranını birlikte göstermektedir. İyi bir ajandan beklenen davranış, kabul oranını yükseltirken hatalı hamle oranını azaltmasıdır.




Şekil 5: Q-tablosu büyüme grafiği

Q-tablosu büyümesi, ajanın eğitim boyunca kaç farklı durumu ziyaret ettiğini göstermektedir. Bu metrik, ortamın keşfedilme düzeyi hakkında bilgi verir.



Şekil 6: Ajanların ortalama ödül karşılaştırması

Karşılaştırma sonuçlarında Q-Learning Agent, Random Agent'a göre belirgin şekilde daha başarılı sonuç üretmiştir. Rule-Based Agent ise elle yazılmış güçlü bir baseline olduğu için Q-Learning Agent'a yakın sonuçlar verebilmektedir. Bu durum, genişletilmiş state uzayında öğrenme performansının reward tasarımı ve eğitim süresiyle yakından ilişkili olduğunu göstermektedir.



Şekil 7: Q-Learning, Rule-Based ve Random ajanların zaman serisi karşılaştırması

9 Değerlendirme

Bu çalışma, reinforcement learning yöntemlerinin kaynak yönetimi problemlerinde kullanılabileceğini göstermektedir. Başlangıçta yalnızca paket boyutuna göre çalışan sistem, genişletilmiş sürümde daha gerçekçi kriterlerle desteklenmiştir. Soğuk zincir ihtiyacı, kırlanlık, öncelik ve XL dolap gibi ek özellikler problemin zorluk seviyesini artırmıştır.

Q-Learning Agent, rastgele karar veren ajana göre çok daha iyi performans göstermiştir. Rule-Based Agent ise güçlü bir kural tabanlı baseline olarak kullanılmıştır. Bu karşılaştırma, Q-Learning yaklaşımının avantajlarını gösterirken aynı zamanda daha büyük state uzaylarında eğitim süresi ve reward tasarımının önemini ortaya koymaktadır.

10 Gelecek Çalışmalar

Bu proje ileride aşağıdaki geliştirmelerle daha da genişletilebilir:

- Deep Q-Network kullanımı
- Paketlerin dolapta kalma süresinin modellenmesi
- Müşteri teslim alma davranışının simülasyona eklenmesi
- Web tabanlı interaktif 3D arayüz geliştirilmesi
- Birden fazla teslimat noktasının aynı anda yönetilmesi
- Multi-agent reinforcement learning yaklaşımı
- Gerçek zamanlı dashboard ile sonuçların izlenmesi

11 Sonuç

Bu projede Q-Learning kullanılarak akıllı kargo dolabı yönetim sistemi geliştirilmiştir. Ajan, gelen paketleri dolapların mevcut durumuna ve paket özelliklerine göre yerleştirmeyi öğrenmiştir. Proje, basit bir boyut eşleştirme probleminden çıkarılarak öncelik, kırılganlık, soğuk zincir ve kapasite koruma gibi daha gerçekçi kriterler içeren bir karar verme problemine dönüştürülmüştür.

Elde edilen sonuçlar, reinforcement learning yaklaşımının akıllı kaynak yönetimi problemlerinde uygulanabilir olduğunu göstermektedir. Özellikle random ajan ile yapılan karşılaştırma, öğrenen ajanın karar kalitesini açıkça ortaya koymaktadır.